

三维体素多机协同覆盖的 MARL 仿真基准与系统评估

摘要

在多无人机协同执行复杂三维覆盖任务时，覆盖率与任务完成率两类指标常被不加区分混用，导致不同算法性能难以公平横向对比。同时该领域缺少一套可复现、指标定义统一的多智能体强化学习 (MARL) 仿真评测基准。为此，本文构建基于三维体素的仿真环境 GridWorld3DEnv，设计 Medium、Hard 两套标准化评测协议。将经典价值分解算法 QMIX 作为基线，在统一协议下与 VDN 开展对照实验，实验结果表明：在多智能体协同规模更大的 Hard 档位配置下，QMIX 综合性能更优，任务完成率更高、平均执行步数更少，该趋势在全部随机种子下保持一致（非统计显著性结论）。Medium 场景中出现高覆盖率、低任务完成率的指标背离现象；针对势能奖励塑形 (PBRs) 模块开展单变量消融实验，证明该模块在本文仿真配置下性能增益有限。本文完整开源仿真环境、实验代码与数据集，可为三维无人机协同覆盖领域提供标准化评测平台，规范该领域算法实验流程与评价体系。

关键词：多智能体强化学习；覆盖路径规划；无人机；三维体素仿真；价值分解；奖励塑形

第 1 章 引言

1.1 研究背景

在城市空中交通、复杂地形搜救或室内受限空间巡检等任务中，低空无人机需要在有限续航和弱通信条件下，对目标的三维空间体积实现全面覆盖 [1]。这类任务远比二维平面覆盖复杂：障碍物在垂直方向上呈碎片化分布，层与层之间的机动约束也更显著，而多机之间往往还缺乏明确的协同链路。传统上，基于几何分解或启发式搜索的覆盖路径规划 (Coverage Path Planning, CPP) 方法在这样的场景下，很难同时兼顾全局可通行体素的完整覆盖和多机间的有效分工 [1][2]。

多智能体强化学习 (Multi-Agent Reinforcement Learning, MARL) 通过学习智能体与环境的交互来涌现分布式协同策略，为上述挑战提供了一条可扩展的解决路径 [3]。目前，「集中式训练、分布式执行」(Centralized Training with Decentralized Execution, CTDE) 已成为该领域的主流框架 [4][5]。其中，以 VDN、QMIX 为代表的价值分解方法，能够在联合动作空间 $|\mathcal{A}|^N$ 指数级扩张的情况下，依然保持一个可训练的结构 [6][7]。

1.2 现有 MARL 评测基准缺口

尽管 MARL 方法在不断进步，但面向三维体素全覆盖 CPP 任务的公开评测基准仍存在三方面明显不足：(i) 主流平台大多不支持或未标准化三维体素的完全覆盖任务；(ii) 覆盖率 (coverage) 与任务完成率 (completion success) 的评判标准不统一，这使得算法性能无法公平对照；(iii) 缺少能在同一协议下公平对比 QMIX/VDN 等价值分解算法的标准化评测协议（更详细的对比请见第 2 章表 1）。这些缺位，制约了三维多机覆盖领域内算法与协议的可复现性研究，也导致了 coverage 与 success 等指标常被无意识地混用和误读。

1.3 本文研究定位

本文的核心贡献不在于设计新的 MARL 算法，而是聚焦于为三维无人机协同覆盖领域构建一个标准化的仿真基准并进行系统的实证研究。我们的目标是搭建一个可复现的环境和统一的评测协议，并在此框架下对 QMIX 与 VDN 的参考实现进行公平对比，再辅以一系列配套实验。第 5 章和第 6 章中所有的实证结论与现象解读，都严格限定在本文所设定的环境与协议框架之内，我们并不对跨环境或跨场景的泛化性能做任何推断。

1.4 本文主要贡献

本文的主要贡献体现在以下四个方面：

- (1) 搭建了一个开源的三维体素仿真环境 GridWorld3DEnv，并设计了 Medium/Hard 两档标准化评测协议。该协议统一了体素全覆盖的判定规则与评价指标口径，相关环境参数和指标体系详见表 2、表 3。
- (2) 在 CTDE 框架和统一的评测协议下，完成了 QMIX 与 VDN 算法的对照实验，明确了在复杂三维场景中这两类价值分解算法的性能差异，完整的实验与对比分析见第 4 章至第 5 章。
- (3) 我们引入了一个任务复杂度难度指数 D 和归一化步数预算 B_{norm} (定义见式 (2))，为定量解析档位间的指标背离现象，尤其是理解覆盖率与任务完成率为何不一致，提供了一个可计算的分析框架。相关的机理讨论详见第 5 章。

(4) 我们还进行了 PBRs 单变量消融、启发式基线对照以及 Hard 档 $n = 5$ 探索性扩展等多组实验，以全面验证我们评测模块与协议设计的有效性。全部环境、代码与数据集均已开源（详见 6.4 节），希望为社区提供一个可复现的评测平台。

1.5 论文章节安排

第 2 章综述了 CPP、MARL 领域的研究现状与现有评测基准；第 3 章则详细介绍了 GridWorld3DEnv 环境的建模、基于 CTDE-QMIX 的协同控制架构以及我们的基准评测协议；第 4 章呈现了实验设置与结果；第 5 章围绕现象解读、统计边界以及评测基准的适用范围展开讨论；最后，第 6 章给出结论、研究局限与未来展望。附录部分补充了复现路径、启发式轨迹示意、探索性统计以及 $n = 5$ 的探索性扩展实验。

第 2 章 相关工作

2.1 覆盖路径规划与三维环境表征

覆盖路径规划（CPP）的核心任务，是让移动平台在有效避障的同时访问所有目标区域 [1]。在二维场景下，基于几何分解、牛耕法与启发式优化的方法已相当成熟 [1]。但当任务扩展到城市空中交通、室内巡检等三维空间时，高度维度的约束和拓扑的碎片化使得这些平面方法难以直接应用 [1][8]。体素地图（voxel map）通过将三维空间剖分为规则的离散单元，用体素标记来编码障碍物和可通行区域，为对接深度强化学习提供了便利的接口 [9]。虽然体素化会引入离散化误差，但它能显著降低仿真的复杂度 [9]。现有的 UAV 三维规划研究常将障碍物密度 ρ 设定在 10%–30% 甚至更高 [8]，加之多机协同与碎片化的通道，进一步推高了规划与协调的难度，促使研究者们采用学习型策略 [2][10]。一个适配 MARL 训练流程的三维体素 CPP 任务，需要离散的环境表征与标准化的全覆盖判定规则。但遗憾的是，现有的二维 CPP 基准或高保真连续仿真器，都无法提供一个兼顾两者与多机协同的统一评测协议。这正是我们构建 GridWorld3DEnv 的初衷——在第 3 章中，我们将详细阐述它如何通过规则化的体素地图与标准化的任务完成判定，来填补这一评测环境的空白。

2.2 多智能体强化学习与协同决策

MARL 让多个智能体通过交互学习协同策略 [3]。其中，Dec-POMDP 模型为刻画分布式执行与局部观测提供了理论框架 [11][12]，而 CTDE 范式因在训练时利用全局信息、执行时仅依赖独立决策，已成为多机协同学习的主流 [4][5]。在价值分解方法中，VDN 通过假设 $Q_{\text{tot}} = \sum_i Q_i$ 来分解联合价值函数 [6]，QMIX 则引入一个单调混合网络，保证了局部贪心策略与全局贪心策略的一致性 [7]。这两者正是我们选定的参考实现。需要注意的是，联合动作空间的规模为 $|\mathcal{A}|^N$ ，它会随无人机数量的增加而指数级膨胀 [3][6]。

近年来，UAV 协同与 MARL 的结合正持续向三维空间和异构系统拓展。例如，Ali 等人 [13] (2024) 在 2D/3D 覆盖场景中对 PPO、MADDPG 等算法进行了系统性的横评，揭示了算法与场景的匹配差异；Ramezani 等人 [14] (2024) 提出了一个容错的 UAV-UGV MARL 框架，以应对通信中断与节点失效；Zhao 等人 [15] (2025) 则在三维信息采集任务中采用了 COMA 这类 CTDE 方法协调多机探索。这些工作表明该领域仍非常活跃。然而，它们大多侧重于连续空间的物理仿真、异构协同或区域遍历类指标，尚未形成一个面向三维体素全覆盖任务、可在统一协议下直接对比 QMIX 与 VDN 的轻量级评测基准。因此，即便是在 CTDE 架构下，领域内依然缺少一个标准化的场景来公平对比不同的价值分解算法。这正是我们在 GridWorld3DEnv 中固化 CTDE 训练与分布式执行接口，并以 QMIX 为基线、VDN 为对照，实现两者在复杂三维体素场景下可复现横向对比的出发点（详见第 3–4 章）。

2.3 奖励塑形与稀疏探索机制

三维体素全覆盖是一个典型的长视界稀疏回报任务 [2][10]。为缓解这一问题，基于势能的奖励塑形（PBRs）通过势函数差分注入稠密的引导信号 [16]。Ng 等人证明，在单智能体 MDP 下，PBRs 能保持最优策略不变 [16]。但在多智能体团队回报的场景下，它通常仅作为一种工程近似 [17][18]。此外，事件型的分项奖励可以与势差项解耦，直接编码碰撞、重访以及覆盖新体素等行为约束 [19][20]，与 PBRs 叠加后，有望在引导探索的同时兼顾行为的可行性 [16][19]。

在体素全覆盖任务中，奖励设计必须同时考虑探索效率与无人机的行为约束。将事件惩罚与 PBRs 势差相结合的层级化奖励组合，已经在 CPP 类的 MARL 任务中得到了广泛验证。在 GridWorld3DEnv 中，我们将「事件惩罚 + PBRs 势差」设定为标准评测基准配置，并在 4.5.1 节通过 PBRs 单变量消融实验，来检验势差项的边际贡献，从而为后续在同一奖励接口上开展多算法对照提供一个可复现的基线。

2.4 现有 MARL 评测基准与领域缺口

表 1 对比了 MATE[20]、MARVEL[21]、Bialas 等人 [10] 的工作与我们的 GridWorld3DEnv，主要考察它们在三维体素 CPP、多机协同、QMIX/VDN 同协议对照以及 completion success 这四项能力上的差异。

表 1 现有主流 MARL 评测基准与 GridWorld3DEnv 功能对比（文献依据见 [10][21][20]）

平台 / 基准	3D 体素 CPP	多机协同	QMIX/VDN 同协议对照	completion success
MATE [20]	不支持 (2D 目标覆盖控制)	支持	支持 (含 QMIX 等)	不支持 (目标 exposure 率, 非体素满覆盖)
MARVEL [21]	不支持 (2D 室内探索建图)	支持	部分支持 (CTDE 类 MARL, 非体素 CPP 协议)	不支持 (探索/建图指标)
Bialas 等 [10]	支持 (三维布尔体素栅格 CPP)	部分支持 (单智能体)	不支持	不支持 (TA 面覆盖, 非体素满覆盖终止)
GridWorld3DEnv (本工作)	支持	支持	支持	支持 (正常终止 (terminated) 且 coverage $\geq$ 0.99)

表 1 注：文献功能对比 (非实验重复)；评测协议：不适用；随机种子数：不适用；数值格式：定性对比；completion success 定义见表 3。

表 1 解读。从对比中可以清晰地看到：MATE 聚焦于二维目标曝光控制，MARVEL 面向室内探索建图，而 Bialas 等人的工作虽采用了三维体素栅格，但侧重单智能体的 TA 面覆盖。这三者均未能同时提供体素满覆盖的 completion success 判据和 QMIX/VDN 的同协议对照。GridWorld3DEnv 是首个同时支持三维体素 CPP、多机协同、价值分解算法同协议对照以及体素全覆盖判据的轻量级 MARL 仿真基准。它在保持离散体素、低入门门槛的前提下，将实验焦点收敛至多机协同覆盖与算法/协议的公平对照上（第 3 章）。这与 2.2 节所述的前沿进展形成了互补关系：后者在推动算法与任务的边界拓展，而我们则以一个可复现的基准，补齐了一体化评测的缺口。

第 3 章 方法

统计口径说明（读表读图前必读）。全文严格区分两类结果展示：(i) **训练动态**——图 3、图 4 中的逐回合/滚动曲线，刻画的是训练过程的演变；(ii) **基准评测聚合指标**——表 4、表 5 等在固定协议下，对所有训练回合进行跨随机种子的聚合统计 (mean $\pm$ std)。这两类结果源于同一批 rollout 数据，但统计窗口与聚合方式不同，**切勿直接进行数值对比**。完整的协议请见 3.4 节。

3.1 三维体素环境建模与任务接口

我们将 CPP 任务建模为在一个离散的三维体素地图上进行的多智能体探索问题。环境可以表示为一个离散集合：

$$\mathcal{G} = \{(x, y, z) \mid x \in [0, W), y \in [0, H), z \in [0, L)\} \quad (1)$$

其中， $\mathcal{G}$ 是全体素坐标集合； (x, y, z) 是体素索引； W 、 H 、 L 分别是宽、高、深（层）方向上的体素数量； ρ 代表障碍物密度； N 是无人机数量； $T_{\max}$ 是单个回合的最大仿真步数。

在地图中，每个体素在逻辑上属于三类之一：障碍体素、可通行且已访问体素，或可通行但未访问体素。环境初始化时，会按照 ρ 随机布撒静态障碍体素，且在一个回合内，障碍分布保持不变。

任务形式化。在 CTDE 框架 [4][5] 下，我们将覆盖任务建模为一个协同的多智能体 MDP (Dec-POMDP/CTDE 的基础见 2.2 节，此处不再赘述)。下文将重点描述 GridWorld3DEnv 的环境动力学、动作空间、观测接口、终止规则和跨档难度量化方式；算法的具体实现则在 3.2 节介绍。

动作空间。我们将单智能体的动作空间 $\mathcal{A}$ 定义为沿 X 、 Y 、 Z 三轴正负方向的六个邻域机动动作。这样， $|\mathcal{A}| = 6$ ，而 N 架无人机的联合动作空间规模则为 $|\mathcal{A}|^N$ ，会随 N 呈指数级增长。我们采用这种简化的离散动作设计，是为了降低基准的使用门槛，让研究的焦点集中在多机协同与覆盖策略上，而不是精细的飞行动力学控制。

观测设计。观测编码函数 $\phi(s_t)$ 会将三通道的体素图（已访问、障碍、UAV 占用）展平为向量，再与覆盖率、各机的归一化位置和能量等标量拼接成一个固定维度的向量。在训练与 rollout 阶段，我们让 $o_t^i = \phi(s_t)$ ，并将 $\phi(s_t)$

复制给每一个智能体作为输入。这样做是为了保证 QMIX 和 VDN 在完全相同的信息条件下进行公平比较。在执行期，各机则独立输出动作，彼此之间没有显式的通信。

能量与截断。每架 UAV 都有一个独立的能量池，每次成功移动消耗 1 点能量。当总步数达到 $T_{\max}$ 或所有无人机的能量都耗尽时，回合会被记为 **提前截断** (truncated)。在表 2 的配置下，单回合步数上限 $T_{\max}$ 低于各机的能量上限，因此主实验中的截断是由 $T_{\max}$ 主导的（表 4、表 5 中 steps 的均值也接近 $T_{\max}$ ）。能量耗尽条件，是环境预留的一个扩展接口。

表 2 给出了 Medium 和 Hard 两档 **MARL scaling** 的配置（包括体素规模、 ρ 、 N 、 $|\mathcal{A}|^N$ ），需要特别指出的是，这并非 completion 难度的单调标尺。关于跨档 success 的解读，请见第 5 章。

跨档 completion 难度量化 (本文原创指标)。一个常见的误判是，仅凭 Medium/Hard 这类标签或地图规模来推断 success 的高低，却忽略了 V_{free} 、 N 和 $T_{\max}$ 共同决定的 completion 预算。例如，在第 5.3 节中我们将看到，Hard 档的 scaling 更高，但由于其 D 值更低，success 反而更高。为了化解跨档位 completion 难度的误判，我们提出了 **completion 难度指数 D** (Difficulty Index) 与 **归一化步数预算 B_{norm}** (Normalized Step Budget):

$$D = \frac{V_{free}}{N \cdot T_{\max}}, \quad B_{norm} = \frac{1}{D} = \frac{T_{\max}}{V_{free}/N} \quad (2)$$

其中 V_{free} 是可通行体素的总数。 D 衡量的是在单位「agent-step」预算下，待覆盖体素的负载： D 越大，意味着 completion 越困难； B_{norm} 则代表每架无人机为覆盖每个可通行体素平均能用的仿真步数上限，且 $B_{norm} = 1/D$ 。这两个指标将跨档的 success 差异，从经验标签转化为可核算的配置量，是我们定量解析 coverage-success 背离以及跨档对照的核心工具（表 2、表 9；第 5.3 节）。指标口径亦见表 3 与表 2 注。

表 2 Medium 与 Hard 档位基准环境参数

配置	体素地图尺寸 $L \times H \times W$	ρ	N	V_{free}	$T_{\max}$	D	B_{norm}	能量预算 [†]
Medium	$8 \times 6 \times 6$	0.08	2	100	2500	0.02080.0	0.02080.0	4500 (每机)
Hard	$4 \times 7 \times 7$	0.12	3	173	3500	0.01660.7	0.01660.7	6000 (每机)

表 2 注：本表列出的是 Medium 和 Hard 两档固定的环境静态参数。 D 与 B_{norm} 由式 (2) 计算得出； V_{free} 是地图初始化后统计的可通行体素总量，而障碍密度 ρ 是随机采样的期望值，单张地图的实际值可能存在小幅波动。 D 表征了单位步预算下的覆盖难度， B_{norm} 是等价的归一化步数上限。由于两档在协同规模和步数预算上存在明显差异，任务完成率不可跨档直接对比（详见第 5 章）。主实验以步数上限 $T_{\max}$ 作为提前截断的核心判定依据，能量预算[†] 仅作配套约束。




图 1: GridWorld3DEnv 三维体素仿真环境示意图, 左侧是 Medium 档位、右侧是 Hard 档位。图中灰色方块代表障碍体素, 彩色三角标记的是无人机的初始投放位置。

图 1 直观展示了两档位下三维体素地图的障碍分布。Medium 档地图空间紧凑、障碍密度更低, 便于我们观察双机协同下的区域覆盖拓展过程; 而 Hard 档尺寸更大、障碍分布更密集, 采用了三机协同架构, 其垂直分层结构更为突出, 对应着更大的联合动作空间与步数预算, 旨在验证在碎片化的三维场景中, 多机避障与分工覆盖的能力。

3.2 基于 CTDE 与 QMIX 的协同控制架构

面对由 $|\mathcal{A}|^N$ 带来的协同学习挑战, 我们采用 QMIX[7] 作为 CTDE 框架下的参考实现 (CTDE 范式见 2.2 节)。观测接口的设计依据 3.1 节, 奖励的定义则在 3.3 节详细说明。

QMIX 价值分解。系统包含 N 个 **GRU-Q** 网络, 每个输出一个个体价值 Q_i 。各机以 3.1 节所述的观测 o_t^i 为输入, 独立解码出动作 $\pi_i(a_t^i | o_t^i)$ 。混合网络则以全局状态 s_t (t 为仿真步索引) 为条件, 生成非负权重 $w_i(s_t) \geq 0$, 并满足单调性约束:

$$\frac{\partial Q_{\text{tot}}}{\partial Q_i} = w_i \geq 0 \quad (3)$$

其中, Q_{tot} 是全局联合价值, Q_i 是第 i 架无人机的局部价值, w_i 是混合网络生成的非负权重。该网络的条件输入是与 $\phi(s_t)$ 同构的全局状态特征。在训练阶段, 我们在 TD 目标下学习这种非线性的联合价值; 到了执行阶段, 每架 UAV 只需运行其本地的 **GRU-Q** 网络, 进行贪心解码即可。




图 2: 基于 CTDE 框架的 QMIX+PBRS 协同决策数据流架构，适配本文全部的 Medium、Hard 双档仿真场景。

图 2 完整梳理了训练与决策的流程：环境在每一步都会输出事件惩罚与势差塑形回报（式 (4)–(6)），训练阶段则聚合各无人机的局部价值来构建时序差分损失；PBRS 势差的消融对照实验详见 4.5.1 节。

3.3 奖励塑形与事件惩罚机制

三维全覆盖是一个长视界目标，除了回合结束时可能获得的 r_{complete} 外，更需要逐步的引导信号来缓解奖励稀疏问题。因此，我们将每步的团队回报设计为：

$$r_t = \lambda_1 r_t^{\text{event}} + \lambda_2 r_t^{\text{PBRS}} \quad (4)$$

其中， r_t 是团队逐步回报； r_t^{event} 包含了事件惩罚与覆盖激励项； r_t^{PBRS} 是 PBRS 势差项； $\lambda_1, \lambda_2 \geq 0$ 是各项的权重（若省略，则默认均为 1）。主实验中，我们取 $\lambda_1 = \lambda_2 = 1$ ，而 PBRS 的内部尺度则由式 (6) 的 w_s 单独控制（在 4.5.1 节的消融实验中，通过将 w_s 置零来关闭 PBRS 项）。

分项设计目的。 (i) **事件惩罚与覆盖激励** r_t^{event} ：这一项与势函数无关，主要用来约束碰撞、重访、触碰障碍物或边界等无效或违规行为，同时提供与覆盖新体素相关的逐步进度信号，使得策略在获得稀疏的终局回报之前，也能从这些即时反馈中学习。(ii) **PBRS 势差项** r_t^{PBRS} ：引入此项，是为了缓解长视界下的稀疏奖励问题，它通过势函数差分来引导智能体向未覆盖的区域移动，以加速探索的推进（经典的 PBRS 性质见 2.3 节）。

事件惩罚与覆盖激励 (r_t^{event}) 具体包含：触碰障碍/边界的惩罚 r_{obstacle} 、机间碰撞的惩罚 $r_{\text{collision}}$ 、重访已覆盖体素的惩罚 r_{visited} 、覆盖新体素的奖励（会随剩余未访问体素数量进行缩放）、无进展时的惩罚，以及当实现全覆盖时均摊的 r_{complete} [19][20]。当消融 PBRS 时，我们设 $w_s = 0$ （即 $\lambda_2 r_t^{\text{PBRS}} \equiv 0$ ），此时仅保留 $\lambda_1 r_t^{\text{event}}$ （实现细节见 6.4 节的 GitHub 仓库）。

PBRS 势差项 (r_t^{PBRS})：Ng 等人给出的经典 PBRS 势差形式 [16] 为

$$F_t = \gamma \Phi(s_{t+1}) - \Phi(s_t) \quad (5)$$

其中， F_t 是经典 PBRS 势差； $\Phi(s)$ 是状态势函数； $\gamma \in [0, 1)$ 是折扣因子。在我们的实现中，势函数 Φ 由到最近未访问可通行体素的 BFS 距离（取负值）与一个障碍安全距离截断项构成，并采用了如下工程近似：

$$r_t^{\text{PBRS}} = w_s (\Phi_{t+1} - \Phi_t) \quad (6)$$

其中, w_s 是势函数的权重; $\Phi_t = \Phi(s_t)$, $\Phi_{t+1} = \Phi(s_{t+1})$ 。需要说明的是, 式 (6) 并没有显式引入折扣因子 γ , 它是一种以探索引导为目标、换取实现简洁性的工程变体, 因此不保证严格的最优策略不变性 [17][18]。4.5.1 节将通过置零 w_s 来检验它的边际贡献。

3.4 训练流程与基准评测协议

两类统计口径 (与章首说明一致)。我们再次强调, 本文的实验结果分为两类呈现, 读者需要加以区分: (i) **训练动态**——图 3、图 4 展示的是逐回合的 coverage 或 success 滚动均值, 用于观察训练过程的演变, 它并非主表中的聚合均值; (ii) **基准评测聚合指标**——表 4、表 5 等在 **基准评测协议** 下, 对 2000 回合/随机种子的全部训练回合聚合了 coverage / success / steps (见表 3 定义), 并报告跨随机种子的 mean $\pm$ std。两者源于同一环境和 rollout, 但统计窗口与聚合层级不同, **所以不能将曲线上的读数与主表中的数值直接画等号。**

QMIX/VDN 主表 (表 4、表 5)。在每个随机种子上完成 2000 回合的训练后, 我们按表 3 的定义, 对全部回合的 coverage / success / steps 进行聚合。rollout 时采用 ϵ -greedy 衰减策略。下文将此口径称为 **基准评测协议** (实现细节见 6.4 节的 GitHub 仓库、附录 A)。

探索性扩展。Hard 档的 QMIX-VDN 对比, 我们从 $n = 3$ 个随机种子扩展到了 $n = 5$ (见表 15)。**关于随机种子规模的说明:**主表的 $n = 3$ 和扩展的 $n = 5$ 都属于探索性规模, 这个样本量并未达到多算法对比领域通用的最小要求 ($n \geq 10$)。因此, 正文中的主要对比, 我们避免使用「显著优于」这类带有统计显著性意味的措辞, 而是采用「各随机种子指标方向一致」以及探索性效应量 (见 5.6 节、表 12–15) 来描述我们的发现。

启发式方法 Greedy/Random 不涉及训练, 其结果见表 6。

QMIX/VDN 采用 CTDE + 经验回放 ($\gamma = 0.99$, 探索率衰减至 0.05)。超参数与汇总流程详见 GitHub 仓库 (6.4 节)。

3.5 评价指标 (全文统一术语)

表 3 汇总了全文所使用的核心评价指标。主表 (表 4、表 5) 将按照基准评测协议 (3.4 节), 报告 mean $\pm$ std ($n = 3$ 随机种子, 探索性规模)。

表 3 评价指标与终止状态定义

记号	含义
coverage mean	各回合末帧覆盖率的均值
success mean	任务完成率: 正常终止 (terminated) 且末帧 coverage ≥ 0.99 的回合所占比例
steps mean	单回合平均执行步数
terminated	正常终止: 所有可通行体素已被访问完毕
truncated	提前截断: 步数达到 $T_{\max}$ 或所有无人机能量耗尽; 不计入 success
revisit mean	单回合内 重访体素次数 : 所有 UAV 在每步落入已访问可通行体素的累计次数 (表 7)
overlap mean	单回合 机间重叠次数 : 同一仿真步内, 多架 UAV 竞争同一目标体素导致的冲突计数 (表 7)
η_{cov} (覆盖效率)	$\eta_{\text{cov}} = \text{coverage}/T$; T 为单回合团队步数 (表 7)。该指标单独使用不足以反映路径冗余与机间冲突, 须与 ρ_{red} 、 C_{norm} 联合解读 (5.5 节)
C_{norm} (归一化路径代价)	$C_{\text{norm}} = (T \cdot N + R_{\text{revisit}})/V_{\text{covered}}$; V_{covered} 为回合末已访问可通行体素数, R_{revisit} 为重访体素次数 (表 7)。此值越大, 代表完成覆盖所消耗的 agent-action 越冗余
ρ_{red} (冗余运动比)	$\rho_{\text{red}} = R_{\text{revisit}}/(T \cdot N)$ (表 7); Random 在 Medium 档此值可达 $\approx 93\%$, 表明 completion 伴随了很高比例的重访体素 (见表 7 数值)
E (唯一覆盖效率)	$E = V_{\text{covered}}/T$ (等价于 $\eta_{\text{cov}} \cdot V_{\text{free}}$ 在 success 回合); 表 7
D (completion 难度指数)	Difficulty Index: $D = V_{\text{free}}/(N \cdot T_{\max})$ (式 (2)); D 越大, completion 越难; 跨档比较 success 时必须报告此指标 (表 2、5.3 节)

记号	含义
B_{norm} (归一化步数预算)	Normalized Step Budget: $B_{norm} = 1/D$ (式 (2)): 与 D 等价, 表示每架无人机为覆盖每个可通行体素平均能用的仿真步数上限

表 3 注: 指标定义表; 评测协议: 见 3.4 节基准评测协议; 主表聚合见表 4、表 5 (随机种子数 $n = 3$, 探索性); terminated/truncated 分别译作正常终止/提前截断。

coverage mean 与 success mean 的口径不同 (表 3), 二者的具体关系分析见 4.3 节与 5.4 节。在学习类方法的主排序中, 我们以 **success mean** 为主要指标、**steps mean** 为辅助指标 (表 4、表 5)。

第 4 章 实验设置与结果

本章将呈现实验结果, 并按照四层逻辑来组织: (1) QMIX/VDN 主算法对比; (2) Medium 档 coverage-success 的指标背离现象; (3) 启发式基线的表现与路径冗余分析; (4) PBRs 消融实验与对障碍密度的敏感性分析。指标的定义见 3.5 节; 训练动态与基准评测聚合结果的口径说明见 3.4 节; 现象背后的机理与统计边界将在第 5 章进行讨论。

随机种子规模说明。主表的 $n = 3$ 和 Hard 档扩展的 $n = 5$ 均属探索性规模, 未达到多算法对比领域通用的最小样本量要求 ($n \geq 10$)。因此, 正文中不会做出「显著优于」这类统计推断。对于 Hard 档 QMIX-VDN 的主要对比, 我们采用「各随机种子指标方向一致」来描述观察到的趋势 (详见 5.6 节)。

4.1 实验约定

环境参数同表 2 (3.1 节); QMIX/VDN 的训练与基准评测协议见 3.4 节。关于 Hard 档价值分解的主要结论, 应以 QMIX vs VDN (同协议、表 5) 的对比为准。Greedy/Random 作为启发式参考, 不参与学习类方法的排序 (表 6-7)。

4.2 第一层: QMIX/VDN 主算法对比

训练动态与主表对照。图 3、图 4 展示了训练期间 coverage 与 success 的滚动演化过程 (并非表 4/5 的聚合均值); 表 4、表 5 则是基于 2000 回合/随机种子的基准评测聚合结果 ($n = 3$, 探索性)。




图 3: 在 Medium 和 Hard 档位下, QMIX 与 VDN 训练过程中覆盖率的变化曲线。左子图为 Medium 场景, 右子图为 Hard 场景。这些曲线仅反映训练动态, 与表 4、表 5 中的聚合评测指标统计口径不互通。

从图 3 可以看出, 两类算法的单回合覆盖率都随着训练迭代而稳步提升。在 Hard 场景的训练末期, QMIX 的曲线整体位于 VDN 之上, 这与表 5 中它更高的平均覆盖率和任务完成率是吻合的。而在 Medium 场景中, 两种算法的覆盖率都能达到 0.85-0.90, 但全局完成率的均值仅为 0.10 左右, 这个指标背离现象我们将在 4.3 节展开分析。

Training-phase completion success (not identical to Table 4–5 eval aggregates)




图 4: 训练阶段全域覆盖完成率的 80 回合滚动均值曲线, 左侧为 Medium, 右侧为 Hard。滚动均值仅用于观测训练趋势, 不能与表 4、表 5 的聚合评测结果直接等价。

由图 4 可见, 在 Hard 档位的训练后期, QMIX 的完成率滚动均值持续高于 VDN。而在 Medium 档位, 两类算法的全域覆盖完成比例长期处于低位, 这与表 4 统计得出的低平均完成率保持一致。

表 4 Medium 档 QMIX/VDN 基准评测结果

算法	coverage mean	success mean	steps mean
QMIX (参考实现)	0.863 ± 0.038	0.099 ± 0.039	2375.4 ± 50.7
VDN	0.707 ± 0.029	0.092 ± 0.039	2380.3 ± 49.8

表 4 注: 实验档位: Medium (表 2, $\rho = 0.08$, $N = 2$); 评测协议: 基准评测 (3.4 节), 2000 回合/随机种子聚合; 随机种子数 $n = 3$ (探索性); 数值格式: 均值 $\pm$ 标准差; 指标定义见表 3。

表 5 Hard 档 QMIX/VDN 基准评测结果

算法	coverage mean	success mean	steps mean
QMIX (参考实现)	0.993 ± 0.001	0.601 ± 0.010	2333.0 ± 6.3
VDN	0.976 ± 0.004	0.465 ± 0.059	2609.7 ± 119.6

表 5 注: 实验档位: Hard (表 2, $\rho = 0.12$, $N = 3$); 评测协议同表 4; 随机种子数 $n = 3$ (探索性); 数值格式: 均值 $\pm$ 标准差; 指标定义见表 3。

在 Hard 档 (表 5), QMIX 的 success mean (0.601) 高于 VDN (0.465), 而 steps mean (2333.0) 则低于 VDN (2609.7)。Hard 档三个随机种子的 success 均高于 VDN 的对应值, 这表明在本实验配置下, QMIX 在 success 与 steps 上的综合表现更优, 且各随机种子的指标方向一致 (并非统计显著性检验的结论)。在 Medium 档 (表 4), QMIX 的 coverage mean 高于 VDN, 但两者的 success mean 都只有 0.10 左右。关于两档对照的进一步讨论见 4.3 节与第 5 章。探索性统计结果见表 12–14 (附录)。

4.3 第二层: Medium 档 coverage–success 指标背离

表 4 和图 3 (Medium 左侧子图) 已经显示出 coverage 与 success 之间存在显著差距, 而图 5 则从单回合层面提供了联合统计的证据。

Medium tier: coverage vs completion success (QMIX training + learning-class aggregates)




图 5: Medium 档位覆盖率与全域完成情况的联合统计分析图, 仅取单个随机种子训练末期 300 回合数据绘制。完整实验共含 3 组随机种子, 指标定义详见表 3。

图 5 直观地解释了 Medium 档的指标背离现象: 平均覆盖率虽然接近 0.86, 但全域完成率仅为 0.10, 平均执行步数也逼近了步数上限 $T_{\max} = 2500$ 。这意味着, 大量回合在实现了高覆盖率后, 仍因步数耗尽而触发提前截断, 无法遍历那些零散分布的剩余可通行体素。简单来说, coverage 反映了探索的广度, 而 success 要求在规定步数预算内访问完所有可通行体素 (表 3)。关于这一现象的成因分析, 我们将在 5.4 节详细展开。

4.4 第三层: 启发式基线与路径冗余

Greedy 和 Random 策略无需训练, 直接进行 rollout, 其目的在于帮助我们理解 coverage/success/路径效率的基准。它们不参与表 4、表 5 的学习类算法排序。

表 6 启发式参考基线 (coverage mean / success mean / steps mean; $n = 3$)

档位	算法	coverage mean	success mean	steps mean
Medium	Greedy	0.543 ± 0.008	0.180 ± 0.000	2061.0 ± 0.0
Medium	Random	1.000 ± 0.000	1.000 ± 0.000	708.0 ± 7.0
Hard	Greedy	0.442 ± 0.001	0.040 ± 0.000	3365.0 ± 0.0
Hard	Random	1.000 ± 0.000	0.987 ± 0.012	1050.0 ± 31.0

表 6 注: 实验档位见表 2; Greedy/Random 无训练过程, 仅进行 50 回合的滚动推演; 随机种子 $n = 3$; 指标定义见表 3。

表 7 覆盖质量与路径代价对照 (定义见表 3; Greedy/Random 为 50 回合/随机种子 rollout, QMIX/VDN 由表 4/5 与训练日志推算)

档位	方法	revisit mean	overlap mean	η_{cov}	C_{norm}	E
Medium	QMIX	4656 ± 109	0.0 ± 0.0	$3.6 \times 10^{-4} \pm 2.3 \times 10^{-5}$	109.2 ± 7.3	0.036 ± 0.002
Medium	VDN	4681 ± 106	0.0 ± 0.0	$3.0 \times 10^{-4} \pm 1.7 \times 10^{-5}$	133.9 ± 8.1	0.030 ± 0.002
Medium	Random	1318 ± 13	11.4 ± 0.5	$1.4 \times 10^{-3} \pm 1.3 \times 10^{-5}$	27.3 ± 0.3	0.157 ± 0.004
Medium	Greedy	4069 ± 1	3013 ± 58	$2.6 \times 10^{-4} \pm 3.9 \times 10^{-6}$	151.0 ± 2.3	0.026 ± 0.001

档位	方法	revisit mean	overlap mean	η_{cov}	C_{norm}	E
Hard	QMIX	6831 ± 102	0.0 ± 0.0	$4.2 \times 10^{-4} \pm 6.3 \times 10^{-6}$	80.9 ± 1.2	0.073 ± 0.001
Hard	VDN	7411 ± 368	0.0 ± 0.0	$3.9 \times 10^{-4} \pm 2.0 \times 10^{-5}$	88.9 ± 4.7	0.066 ± 0.003
Hard	Random	2980 ± 94	28.9 ± 0.5	$9.5 \times 10^{-4} \pm 2.9 \times 10^{-5}$	35.4 ± 1.1	0.185 ± 0.003
Hard	Greedy	10022 ± 0	7317 ± 0	$1.3 \times 10^{-4} \pm 2.2 \times 10^{-7}$	263.3 ± 0.5	0.023 ± 0.001

表 7 注：指标定义见表 3；QMIX/VDN 数据来自 2000 回合训练日志的聚合，启发式基线来自 50 回合推演；随机种子 $n = 3$ 。

在表 6 中，Random 策略的 success mean 高达 1.0 / 0.987，看起来很完美。但表 7 揭示了其代价：revisit mean 很高 (Medium 1318、Hard 2980)， $\rho_{\text{red}} \approx 93\%$ –95%，overlap mean 分别为 11.4 和 28.9。虽然 C_{norm} 低于 QMIX，但这是以极高的路径冗余为代价换来的。这说明，单看高 success 是不足以判断任务难度或方法优劣的。Greedy 策略的 success 很低，而 overlap 极高 (Medium 档 3013)，充分展示了确定性近邻策略在多机竞争下的低效。Random 的轨迹与分层占用情况可见图 8、图 9，它们与表 7 中的 overlap/revisit 计数是相对应的。我们将在 5.5 节进行联合解读。

4.5 第四层：消融实验与障碍密度敏感性

4.5.1 PBRs 单变量消融（补充验证） 消融范围说明。本文的核心贡献在于评测基准的搭建以及 QMIX/VDN 的同协议主对比。我们仅开展 PBRs 的单变量消融（表 8），以检验势差项的边际贡献，其结果不作为主结论。

在 Medium 档，我们仅关闭 PBRs ($w_s = 0$)，其余设置与主实验的 QMIX 一致。表 8 与图 6 进行了对照。

表 8 Medium 档 PBRs 单变量消融

配置	coverage mean	success mean	steps mean
QMIX + PBRs ($w_s > 0$)	0.863 ± 0.038	0.099 ± 0.039	2375.4 ± 50.7
QMIX 关闭 PBRs ($w_s = 0$)	0.861 ± 0.038	0.097 ± 0.031	2377.2 ± 49.8

表 8 注：实验档位：Medium (表 2)；评测协议：同表 4，PBRs 单变量 (w_s 开/关)；随机种子数 $n = 3$ (探索性)；数值格式：均值 $\pm$ 标准差；指标见表 3。

Potential shaping ablation (grid_3d_medium, n=3 seeds)




图 6: 在 Medium 档位下, 开启与关闭 PBRs 势差项的消融实验指标对比柱状图, 三组随机种子训练数据的聚合结果详见表 8。

从图 6 与表 8 的对照中可以清晰地看到, 开启或关闭势差塑形后, 平均完成率仅相差 0.002, 覆盖率和平均执行步数的变化幅度也极小。这有力地表明, 在本文的仿真配置下, PBRs 势差项对算法性能的提升作用十分有限。完整的讨论见第 6.1 节。




图 7: 在 Medium、Hard 固定尺寸地图下, 贪心、随机两类启发式基线在不同障碍密度下的平均覆盖率变化曲线。此实验不涉及 QMIX、VDN 算法的重跑。

4.5.2 启发式障碍密度敏感性 (不含 QMIX) 图 7 在固定地图规格下, 仅针对 Greedy/Random 扫描了障碍密度, QMIX/VDN 并未参与重训 (主方法仅在表 2 的固定 ρ 下训练, 其结果不能被外推来寻找学习类方法的最优障碍率)。可以看到, 随着障碍密度提升, 贪心策略的平均覆盖率出现了显著的波动下降; 而随机策略则不受障碍分布的影响, 始终维持了全域覆盖, 但其代价是极高的路径重复与机间冲突, 这将在 5.5 节的多指标综合评价中详细分析。

4.6 本章小结

本章按照四层逻辑呈现了实验结果: QMIX/VDN 主对比 (表 4-5、图 3-4) → Medium 指标背离 (图 5) → 启发式与路径冗余 (表 6-7、图 8-9) → PBRs 消融与 ρ 敏感性 (表 8、图 6-7)。所有主表的结果均为 $n = 3$ 探索性重复; 现象机理、统计边界与跨档的 D 值解读将在第 5 章展开。

第 5 章 讨论 (Discussion)

本章将在统一协议和表 2 的配置前提下，对第 4 章的结果做进一步的解读。这些讨论在论据性质上分为两类：一类直接援引表 4–7、图 3–4 等可复现的实验输出，是在本文环境下重复验证的；另一类则针对 coverage–success 背离等现象给出事后解释，这些解释尚未经过多场景、多参数的对照检验，因此不能被视为已证实的因果结论，也不宜外推至其他环境。§5.2–5.3、§5.5 前半部分与 §5.6 以前者为主；§5.4 及 §5.5 中的相应段落属于后者。

5.1 实验约定与结果阅读边界

Medium/Hard 标记的是 MARL scaling 的扩展难度，而并非 completion 难度的单调标尺。Hard 档的 success 高于 Medium，这不足以说明实验设计有缺陷（见 5.3 节）。主表的 $n = 3$ 和 Hard 扩展的 $n = 5$ 均为探索性规模，我们不进行统计显著性推断。QMIX–VDN 的主对比采用「各随机种子指标方向一致」的表述（详见 5.6 节）。正文的对照范围是 QMIX vs VDN 的同协议主表（表 4、表 5）；Greedy/Random 是启发式参考；策略梯度的实现仅作归档于附录 C（非对照实验）。

5.2 QMIX 与 VDN 对照解读

以下判断均直接对应 Hard/Medium 档的主表（表 4、表 5）及图 3 的训练动态，可在同协议下复核。

在本文设定的 Hard 档仿真环境与评测协议下（GridWorld3DEnv；表 2： $\rho = 0.12$, $N = 3$, $T_{\max} = 3500$ ；基准评测协议见 3.4 节），表 5 显示 QMIX 的 success mean (0.601) 高于 VDN (0.465)，steps mean (2333.0) 低于 VDN (2609.7)；Hard 档的三个随机种子 success 均高于 VDN 对应值。因此，在本实验配置下，QMIX 在 success 与 steps 上的综合表现更优，且各随机种子的指标方向一致（非显著性检验结论，也不作跨环境或跨协议的泛化）。同档的训练动态（图 3）也显示，QMIX 末期的 coverage 曲线整体高于 VDN。此外，VDN 的 steps mean 跨随机种子的标准差 (± 119.6) 要远高于 QMIX (± 6.3)。

在本文设定的 Medium 档仿真环境与评测协议下（表 2： $\rho = 0.08$, $N = 2$, $T_{\max} = 2500$ ），表 4 显示 QMIX 的 coverage mean 高于 VDN，但两者的 success mean 均只有约 0.10。coverage–success 背离的现象描述见 4.3 节，成因分析见 5.4 节。

5.3 跨档 success 不宜直接比较：completion 难度指数 D

档位命名的含义。我们需要再次明确，Medium/Hard 标记的是 MARL scaling 的档位（地图规模、 ρ 、 N 、 $|\mathcal{A}|^N$ ），而不是 completion success 意义上的单调「难度等级」。在 Hard 档，联合动作空间为 $6^3 = 216$ （Medium 为 $6^2 = 36$ ），障碍更密集、体素更多，对价值分解与三机协同提出了更高的要求——这正是我们命名其为「Hard」的主要意图。但有趣的是，Hard 档在 completion 预算上反而更宽松，这是导致其 success 高于 Medium 的一个可计算的控制变量。

completion 难度指数 D 与归一化步数预算 B_{norm} 。式 (2) 能将跨档的 success 差异，从看似「反常」的现象，转化为「经核算后的预期结果」。 D 刻画的是「待覆盖体素规模」相对于「团队总 agent-step 预算 $N \cdot T_{\max}$ 」的比值： D 越大，completion 越困难； D 越小，预算相对任务就越宽裕。等价地， B_{norm} 表示每机为分摊一个可通行体素所能使用的仿真步数。请见表 2 与表 9 的对照：

表 9 跨档 completion 难度指数 D 与 success 对照

档位	V_{free}	N	$T_{\max}$	D	B_{norm}	QMIX success mean
Medium	100	2	2500	0.0200	50.0	≈ 0.10
Hard	173	3	3500	0.0165	60.7	≈ 0.60

表 9 注：实验档位：Medium/Hard（表 2）；评测协议：式 (2) 核算与表 5 success mean 对照；随机种子数：success 取自表 5 ($n = 3$)；数值格式：配置常数与聚合 mean。

经 D 核算后的结论是：Hard 档的 completion 预算更宽裕，因此 success 更高，这是一个预期内的结果。Hard 档的 D 值比 Medium 档低约 17.5% ($1 - 0.0165/0.0200$)，等价地说， B_{norm} 高了约 21% ($60.7/50.0 - 1$)。两档在 completion 难度上并未做等预算控制。因此，Hard 地图虽大，但三机并行的能力和更高的 $T_{\max}$ ，使得学习型策略在预算内触发正常终止的比例相对更高 (terminated)；而 Medium 档则因为 D 值更高、地图碎片化及扫尾阶段的 completion 率偏低，导致大量回合被提前截断 (truncated) (5.4 节)。由此，我们可以清晰地得出：

Hard 的 success 高于 Medium，这并不表明 Hard 档的 completion 难度更低，也不说明评测基准缺乏区分度——经 D 值核算，这种差异主要源于预算配置，而非 scaling 标签与 success 之间存在单调对应关系。

Hard 之所以为「Hard」，是指其更大的 MARL scaling ($|A|^N$ 、 ρ 、 N 、体素规模)，而非「completion 成功率应该更低」。

如果未来研究需要在 success 意义上构造单调的难度曲线，就应该固定或扫描 D 值（或等价地固定 B_{norm} ）之后再进行比较（6.3 节）。

审稿中可能会遇到这样的疑问：「Hard 档的 success mean（约 0.60）高于 Medium（约 0.10），是否意味着 Hard 更简单？」我们不应做出这样的推断。表 2 和式 (2) 已经给出了明确的答案：Hard 档的 D 更低、completion 预算更宽裕，因此其 success 更高是经难度指数核算后的逻辑结果。关于 Medium 档低 success、coverage–success 背离以及 Random 高 success 的讨论，请继续参见 5.4 与 5.5 节。

5.4 Medium 档位覆盖率与任务完成率背离现象分析

结合表 4、图 3 与图 5 的实测数据，我们观察到一个稳定出现的现象：在 Medium 仿真配置下（表 2），算法的平均覆盖率可达约 0.86，但任务完成率均值仅为 0.10；steps mean 约为 2375，非常接近 $T_{max} = 2500$ 。这意味着，大约 90% 的训练回合在尚未遍历全部体素时，就因步数耗尽而提前截断（truncated），success 记为 0，末态仍残留约 14% 的可通行体素未被访问。图 5 也证实，大量高 coverage 的样本，其 success 依然为 0；QMIX/VDN 的 $1 - success_mean$ 约为 0.90–0.91。

针对此现象，我们给出一个仅基于当前实验观测的事后解释。请注意，这个推论还未经过多场景、多参数的对照实验验证，尚不能作为严格的因果结论：Medium 地图空间相对紧凑（ $3 \times 6 \times 6$ ），但障碍的碎片化将可行区域切割为大量孤立的小区块。在固定的步数预算下，学习型策略虽能逐步扩展已访问区域（coverage 可达 0.85–0.90），但在扫尾阶段，仍需要多机协同访问那些分散的剩余小块，这对路径衔接与分工的要求非常高。因此，大量回合在 coverage 已经较高时，仍因步数耗尽而截断。覆盖率反映的是空间探索的广度进展，而任务完成率则要求在固定预算内完成所有可通行体素的访问。在我们的协议下，这两者刻画的是任务完成的不同阶段，评判标准有本质区别。

5.5 Random 高 success 与多指标综合评价

表 6–7 与图 8–9 的结果非常具有启发性：Random 策略在 Medium/Hard 档的 success mean 可达 1.0 / 0.987。如果只看 success 这一个指标，很容易误判为任务「极其简单」，甚至认为学习类方法「没有必要」。然而，Random 策略的成功伴随了显著的路径冗余与机间冲突——Medium/Hard 档的 revisit mean 分别为 1318 / 2980， $\rho_{red} \approx 93\%$ –95%，overlap mean 为 11.4 / 28.9。它的步数虽低于学习类方法（708 / 1050），但其 C_{norm} （27.3 / 35.4）依然反映出，这是用大量的重访代价换来的高 success。Random 的 η_{cov} 之所以高于未完成 completion 的 QMIX，是因为它在更少的步数内实现了全覆盖，不能因此就单独据此来排序优劣。

这就揭示了一个关键的方法论启示：高任务完成率并不等同于优秀的多机协同策略。success 必须与 η_{cov} 、 C_{norm} 、 ρ_{red} 、overlap 以及 steps 等指标一并报告（表 3、表 7），才能对算法性能或任务难度做出合理的判断——这也是我们评测协议强调多指标并列报告的根本原因。在这个多指标的评价口径下，Random 的高 success 无法单独证明评测基准的任务难度低，也不能以此否定学习类方法的必要性。毕竟，Medium 档学习类方法的 success mean 仍只有 0.10（表 4），Hard 档的 QMIX 为 0.601（表 5），这些数据与 Random 的高冗余、高 overlap 是并存的。

5.6 探索性统计与样本量边界

我们的主实验随机种子数为 $n = 3$ ，Hard 档扩展至 $n = 5$ ，均未达到该领域常用的 $n \geq 10$ 规模。因此，正文中不做出 $p < 0.05$ 意义上的统计显著性推断。下文给出的置信区间、效应量与假设检验结果仅供探索性参考，不能替代大样本的正式统计推断。QMIX–VDN 的主对比，仍以表 5 中「各随机种子指标方向一致」的结论为准。

主实验 ($n = 3$)。结果汇总于表 4、表 5。探索性 95% 置信区间（基于 10000 次 bootstrap）见表 12–14（Hard 档 QMIX [0.592, 0.611]，VDN [0.411, 0.528]）。Mann–Whitney U 双侧检验 $p \approx 0.100$ （不显著）。

探索性扩展 ($n = 5$ ，表 15)。Hard 档 QMIX 的 mean 为 0.588、VDN 为 0.498 ($\Delta \approx 0.090$)。探索性效应量 Cohen's $d \approx 1.91$ 、Cliff's $\delta \approx 0.92$ ，方向与表 5 一致，但同样不能作为 $n \geq 10$ 条件下的正式结论。

5.7 评测基准适用范围小结

表 4-5 及式 (2) 所支持的 QMIX-VDN 对照与跨档 D 值解读, 都限定在离散体素、静态障碍、同构 UAV、共享全局观测及表 2 的两档配置之下。5.4-5.5 节关于指标背离与 Random 路径质量的讨论, 是基于这些结果的延伸解释, 还有待后续实验的进一步检验。不适用场景与拓展路线见第 6 章。

第 6 章 结论与展望

6.1 结论

我们强调, 本文所有的结论都严格限定于 GridWorld3DEnv 仿真环境、表 2 的两档参数配置、离散体素建模以及 3.4 节的基准评测协议内, 不应被外推至其他仿真环境、连续动力学平台或真实部署场景 (详见 6.2 节)。

全文的核心成果可概括为:

- (1) 评测基准的构建。我们构建并开源了一个三维体素多无人机协同覆盖仿真基准 GridWorld3DEnv, 设计了 Medium/Hard 两档标准化评测协议, 统一了 completion success 判据与评价指标口径 (表 3)。这项工作填补了三维体素 CPP 领域内, 可复现对照评测的空白 (表 1)。
- (2) 同协议下的对照发现。在本实验配置下, 我们发现对于 MARL scaling 更高的 Hard 档, QMIX 的综合性能优于 VDN (各随机种子指标方向一致, 非统计显著性结论)。而在 Medium 场景, 我们观测到了覆盖率与完成率的指标背离现象, 这与任务的碎片化特征和步数预算约束相关 (现象见 4.3 节, 分析见 5.4 节)。
- (3) 多指标评价的方法论启示。PBRs 奖励塑形在本配置下增益有限。更重要的是, 我们展示了 Random 策略虽然能完成全覆盖, 却存在严重的路径冗余与多机冲突, 无法直接应用于实际场景。这有力地说明了, success 必须与路径质量指标联合解读 (5.5 节), 这也是我们为三维多机覆盖评测领域带来的一个方法论层面的贡献。

6.2 研究局限性与适用边界

6.2.1 建模局限 体素离散化会引入空间量化误差, 而我们的六邻域动作简化了垂直机动, 并非精细的飞行动力学模型。

环境假设了静态障碍、同构 UAV、共享全局体素观测 ($o_t^i = \phi(s_t)$), 这不是严格的 Dec-POMDP 或局部感知设定。

能量模型只是步数主导截断的一个辅助约束, 并非物理续航模型。

6.2.2 实验局限 主表的 $n = 3$ 和 Hard 扩展的 $n = 5$ 样本量, 均未达到 $n \geq 10$ 的常用对照规模, 不进行统计显著性推断 (5.6 节)。

Medium/Hard 两档的 D 值未对齐, 因此 success mean 不应跨档解释为 completion 难度的单调关系。

在奖励机制方面, 我们仅进行了 PBRs 的单变量消融; QMIX/VDN 也未开展 ρ 值的扫参重训 (图 7 的实验只包含了启发式方法)。

策略梯度类方法 MAPPO[22] 未纳入正文对照 (附录 C 仅为其拓展实现的归档, 并非对照实验)。

6.2.3 应用局限 全部结论均来自轻量级 MARL 仿真; 我们尚未开展高保真飞控、硬件在环或实机试验。

我们不声称任何 Sim-to-Real 或工程部署的可行性。灾害搜救、室内巡检等应用价值, 指的是它在算法预研与协议对照层面的参考意义, 并非已验证的落地能力。

评测基准适用场景。 GridWorld3DEnv 适用于在以下约束下进行 MARL 算法与协议对照: 离散三维体素、静态障碍、同构 UAV、六邻域离散动作、共享全局观测、CTDE 训练 + 分布式执行, 以及体素满覆盖的 completion success 判据。

不适用场景 (结论不得外推):

类别	不适用情形	原因
动力学	连续飞行动力学、姿态控制、风扰与非线性能耗	离散体素移动, 无飞控层建模

类别	不适用情形	原因
环境	动态障碍、时变地图、非体素几何输入	单回合内障碍固定，规则体素剖分
平台	异构 UAV、差异化感知/算力/通信	同构智能体、相同观测接口
感知与通信	局部窗感知、机间间歇/丢包通信	共享全局 $\phi(s_t)$ (3.1 节)
任务与指标	非体素满覆盖 success、实机部署指标	判据与指标集绑定本协议 (表 3)
算法与规模	跨 ρ /地图泛化、 $n < 10$ 显著性推断	主表仅覆盖表 2 两档 (第 5 章)

6.3 未来工作

下述拓展思路均属后续研究规划，任何性能提升效果仍需独立的实验验证，本文不对此做出效果承诺。我们将其分为三个阶段：

短期（在现有评测基准内，1–2 项可验证目标）。将随机种子数扩展至 $n \geq 10$ ，在同一协议下检验 QMIX–VDN 对照的稳健性；完成对混合网络、事件惩罚、探索调度等模块的多变量消融；针对 Medium 档的指标背离问题，在不改变体素动力学的前提下，优化 $T_{\max}$ 、终止判据或扫尾阶段的训练策略，以提升 Medium 档的任务完成均值。

中期（协议扩展，拓展适用场景）。引入动态障碍、局部感知与异构无人机，使设定更贴近实际的 Dec-POMDP 协同场景；在固定难度指数 D 或归一化步数预算 B_{norm} (式 (2)) 的条件下，构造跨档位可对比的任务完成度变化曲线；在统一的全覆盖判定标准下，纳入更多梯度算法开展对照实验。

长期（外部平台对接）。对接高保真无人机仿真器或连续状态–动作空间环境，重新设计环境动力学、观测规则与全覆盖判定条件；探索仿真到实物的迁移与域随机化方案，该方向的任何结论都需要独立的对照实验，不能直接我们从当前的离散体素场景中推导得出。

6.4 代码与数据可用性

仿真环境 GridWorld3DEnv、实验代码、数据集及全部实验结果已在以下地址开源：

<https://github.com/wqing7523-cell/3d-marl-uav-coverage-benchmark>

仓库核心文件（复现入口）：

路径	说明
src/envs/grid_world_3d.py	GridWorld3DEnv 环境实现
train_qmix_3d.py / eval_3d.py	QMIX/VDN 训练与基准评测入口
configs/envs/grid_3d_{medium,hard}.yaml	Medium/Hard 档位配置 (表 2)
experiments/results/medium_qmix_vdn.jsonl	Medium 档训练汇总 (表 4)
experiments/results/hard_qmix_vdn.jsonl	Hard 档训练汇总 (表 5)
experiments/compute_coverage_quality_metrics.py	表 7 覆盖质量指标复算
experiments/stats_bootstrap_ci.py	表 12–14 探索性统计
requirements.txt	Python 依赖

完整的命令、脚本说明与一键运行流程，请参阅仓库的 README.md 和 experiments/DUAL_TABLE_README.md 文件。正文与附录仅给出了协议要点和关键路径，不在此逐一罗列 shell 命令。

6.5 评测基准定位说明

GridWorld3DEnv 被定位为一个面向算法与协议对照的轻量级、可复现 MARL 评测仿真平台 (Medium $3 \times 6 \times 6$ 、Hard $4 \times 7 \times 7$)，而不是工程级的 UAV 部署验证器。实证结论应在 6.2 节划定的边界内解读；第 5 章关于指标背离与路径质量的延伸讨论，以及 6.3 节的长期拓展设想，都没有超出本工作的性能承诺。

附录

附录仅提供复现路径 (A)、补充轨迹示意 (B)、拓展实现归档 (C)、探索性统计 (D) 与 $n = 5$ 扩展 (E); 不重复正文实验描述。表 6–8 见正文第 4 章; 表 10/11 见附录 C (MAPPO 非对照); 表 12–15 见附录 D/E。

附录 A 复现与数据说明 (GitHub)

复现命令统一维护于: <https://github.com/wqing7523-cell/3d-marl-uav-coverage-benchmark>

项目	说明
环境配置	configs/envs/grid_3d_medium.yaml、grid_3d_hard.yaml
基准评测	2000 回合/随机种子训练后聚合全部回合 (表 4、表 5); 详见 3.4 节
主结果	experiments/results_eval/ experiments/results/*.jsonl
表 12–14	paper/appendix_stats_table_d.md
依赖	requirements.txt (Python 3.9, Windows 10 CPU 实验环境)

附录 B 启发式轨迹示意 (正文表 6–7、§4.4)

Random-policy rollout — 3D UAV trajectories (grid_3d_hard, seed 0, episode 1).




图 8: Hard 档 Random 策略三维 rollout 轨迹示意。实验档位: Hard (表 2, $\rho = 0.12$, $N = 3$); 算法: Random (无训练); 评测协议: 单次代表性 rollout; 随机种子数: $n = 3$ 之一; 与表 6、表 7 中 Random 路径指标对应。

Random-policy rollout — per-layer visit counts / step (grid_3d_hard, seed 0, episode 1).




图 9: 与图 8 同次 rollout 的分层体素占用示意。实验档位/算法/协议同图 8; 按高度层展示已访问体素与 UAV 路径投影; 用于对照表 7 中 overlap mean 与 revisit mean。

图 8-9 与 §5.5 节 Random 路径冗余分析对应, 印证 overlap mean 与 revisit mean 的空间含义。

附录 C MAPPO 拓展实现归档 (非正文对照实验)

边界声明。 MAPPO[22] 为仓库内**工程拓展实现** (参考 Yu 等提出的多智能体 PPO 框架), **不属于正文对照实验**, **不得**与表 4/5 横向比较或用于推断三方法优劣。下列表 10/11 及图 10 **仅作**统一协议下后续扩展的工程参考。

表 10 MAPPO 独立 rollout 数值 (coverage mean / success mean / steps mean; $n = 3$; **非正文对照**)

档位	解码	coverage mean	success mean	steps mean
Medium	stochastic	0.689 ± 0.092	0.053 ± 0.050	2455.253 ± 38.843
Medium	贪心解码	0.186 ± 0.022	0.000 ± 0.000	2500.000 ± 0.000
Hard	stochastic	0.992 ± 0.004	0.380 ± 0.191	3024.633 ± 314.975
Hard	贪心解码	0.202 ± 0.030	0.000 ± 0.000	3500.000 ± 0.000

表 10 注: 实验档位: Medium/Hard (表 2); 评测协议: MAPPO 独立 rollout (50 回合/随机种子, **非**表 4/5 基准评测); 随机种子数 $n = 3$; 数值格式: 均值 $\pm$ 标准差; 拓展实现归档, 非正文对照。Hard 档 stochastic 三种子 success 为 0.260、0.280、0.600。

表 11 评测协议差异示意 (Hard 档; **仅供说明协议不同, 非性能排名、非对照结论**)

方法	评测协议	success mean	steps mean
QMIX	基准评测 (2000 回合聚合)	0.601 ± 0.010	2333.0 ± 6.3
VDN	基准评测 (2000 回合聚合)	0.465 ± 0.059	2609.7 ± 119.6
MAPPO	50 回合 checkpoint rollout	0.380 ± 0.191	3025.0 ± 315.0
MAPPO	50 回合贪心解码	0.000 ± 0.000	3500.0 ± 0.0

表 11 注: 实验档位: Hard (表 2); 评测协议: 并列展示 QMIX/VDN 基准评测 (表 5) 与 MAPPO 独立 rollout 之差异; 随机种子数 $n = 3$; 数值格式: 均值 $\pm$ 标准差 (QMIX/VDN 列); **禁止**据此推断三方法优劣或支持正文结论。

数据文件: experiments/results_eval/mappo_{medium,hard}_s{0,1,2}[_greedy].json (**拓展实现归档**)。




图 10: MAPPO Medium 档训练日志 coverage 示意 (拓展实现归档)。实验档位: Medium (表 2); 算法: MAPPO; 评测协议: 50 回合/随机种子 checkpoint rollout (非表 4 基准评测); 随机种子数 $n = 3$; 非正文对照, 仅工程归档 (附录 C)。

附录 D 探索性统计 (表 12–14; $n = 3$)

完整数据见 `paper/appendix_stats_table_d.md` 与 6.4 节路径。因随机种子数 $n = 3$, 下列区间与检验结果仅供探索性参考, **不能替代** $n \geq 10$ 的正式推断。

表 12 Hard 档 success mean 探索性 95% 置信区间

算法	mean	探索性 95% CI
QMIX	0.601	[0.592, 0.611]
VDN	0.465	[0.411, 0.528]

表 12 注: 实验档位: Hard (表 2); 评测协议: 同表 5; 随机种子数 $n = 3$; 数值格式: 探索性 95% CI (bootstrap 10000 次)。

表 13 Medium 档 **success mean** 的探索性 95% 置信区间

算法	mean	探索性 95% CI
QMIX	0.099	[0.056, 0.130]
VDN	0.092	[0.050, 0.126]

表 13 注: 实验档位: Medium (表 2); 评测协议: 同表 4; 随机种子数 $n = 3$; 数值格式: 探索性 95% CI。

表 14 Hard 档 QMIX vs VDN (success mean, 探索性)

- QMIX 三种子: 0.601, 0.611, 0.592
- VDN 三种子: 0.411, 0.528, 0.456
- Mann–Whitney U 双侧检验 $p \approx 0.100$ ($n = 3$, 探索性参考)

表 14 注：实验档位：Hard (表 2)；评测协议：同表 5；随机种子数 $n = 3$ ；数值格式：分随机种子明细与探索性检验。

附录 E Hard 档 $n = 5$ 探索性扩展 (表 15)

表 15 Hard 档 QMIX vs VDN ($n = 5$ ；协议同表 5)

算法	五随机种子 success	mean	95% CI
QMIX	0.601, 0.611, 0.592, 0.579, 0.556	0.588	[0.570, 0.603]
VDN	0.411, 0.528, 0.456, 0.564, 0.532	0.498	[0.444, 0.544]

表 15 注：实验档位：Hard (表 2)；评测协议：同表 5；随机种子数 $n = 5$ (探索性)；数值格式：mean 与探索性 95% CI； $n = 5$ 规模不足，不宜作显著性推断。

数据文件：hard_qmix_vdn.jsonl (6.4 节)。

- [1] Galceran E, Carreras M. A survey on coverage path planning for robotics[J]. Robotics and Autonomous Systems, 2013, 61(12): 1258-1276. <https://doi.org/10.1016/j.robot.2013.09.004>
- [2] Chen J, Wang Z, Li Z, et al. Multi-UAV coverage path planning based on Q-learning[J]. IEEE Sensors Journal, 2025, 25(16). <https://doi.org/10.1109/JSEN.2025.3580995>
- [3] Gronauer S, Diepold K. Multi-agent deep reinforcement learning: a survey[J]. Artificial Intelligence Review, 2022, 55: 895-943. <https://doi.org/10.1007/s10462-021-09996-w>
- [4] Lowe R, Wu Y, Tamar A, et al. Multi-agent actor-critic for mixed cooperative-competitive environments[C]//Advances in Neural Information Processing Systems 30 (NeurIPS 2017). 2017. <https://doi.org/10.48550/arXiv.1706.02275>
- [5] Orr J, Dutta A. Multi-agent deep reinforcement learning for multi-robot applications: A survey[J]. Sensors, 2023, 23(7): 3625. <https://doi.org/10.3390/s23073625>
- [6] Sunehag P, Lever G, Gruslys A, et al. Value-decomposition networks for cooperative multi-agent learning[C]//Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems (AAMAS 2018). 2018. <https://doi.org/10.48550/arXiv.1706.05296>
- [7] Rashid T, Samvelyan M, De Witt C S, et al. Monotonic value function factorisation for deep multi-agent reinforcement learning[J]. Journal of Machine Learning Research, 2020, 21(178): 7234-7284. <https://doi.org/10.5555/3455716.3455894>
- [8] Maboudi M, Homaei M R, Song S, et al. A review on viewpoints and path planning for UAV-based 3-D reconstruction[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023, 16: 5026-5048. <https://doi.org/10.1109/JSTARS.2023.3276427>
- [9] Hornung A, Wurm K M, Bennewitz M, et al. OctoMap: An efficient probabilistic 3D mapping framework based on octrees[J]. Autonomous Robots, 2013, 34(3): 189-206. <https://doi.org/10.1007/s10514-012-9321-0>
- [10] Bialas J, Doller M. Coverage path planning for unmanned aerial vehicles in complex 3D environments with deep reinforcement learning[C]//2022 IEEE International Conference on Robotics and Biomimetics (ROBIO). 2022. <https://doi.org/10.1109/ROBIO55434.2022.10011936>
- [11] Bernstein D S, Givan R, Immerman N, Zilberstein S. The complexity of decentralized control of Markov Decision Processes[J]. Mathematics of Operations Research, 2002, 27(4): 819-840. <https://doi.org/10.1287/moor.27.4.819.297>
- [12] Oliehoek F A, Amato C. A concise introduction to decentralized POMDPs[M]. Cham: Springer, 2016. <https://doi.org/10.1007/978-3-319-28929-8>
- [13] Ali M A, Maqsood A, Athar U, Khanzada H R. Comparative evaluation of reinforcement learning algorithms for multi-agent unmanned aerial vehicle path planning in 2D and 3D environments[J]. Drones, 2025, 9(6): 438. <https://doi.org/10.3390/drones9060438>

- [14] Ramezani M, Amiri Atashgah M A, Rezaee A. A fault-tolerant multi-agent reinforcement learning framework for unmanned aerial vehicles–unmanned ground vehicle coverage path planning[J]. *Drones*, 2024, 8(10): 537. <https://doi.org/10.3390/drones8100537>
- [15] Zhao Z, Chen C, Shi H, et al. Towards robust multi-UAV collaboration: MARL with noise-resilient communication and attention mechanisms[J]. *arXiv preprint arXiv:2503.02913*, 2025. <https://doi.org/10.48550/arXiv.2503.02913>
- [16] Ng A Y, Harada D, Russell S. Policy invariance under reward transformations: Theory and application to reward shaping[C]//*Proceedings of the 16th International Conference on Machine Learning (ICML 1999)*. 1999: 278-287.
- [17] Devlin S M. Potential-based reward shaping for knowledge-based, multi-agent reinforcement learning[D]. York: University of York, 2013.
- [18] Ying J, Li Z, Dong Z, et al. Generalizable collaborative search-and-capture in cluttered environments via path-guided MAPPO and directional frontier allocation[J]. *arXiv preprint arXiv:2512.09410*, 2025. <https://doi.org/10.48550/arXiv.2512.09410>
- [19] Huang Y, Wang Y, Li Z, et al. A hierarchical multi-robot coverage strategy for large maps with reinforcement learning and dense segmented siamese network[J]. *IEEE Robotics and Automation Letters*, 2025, 10(1). <https://doi.org/10.1109/LRA.2024.3502067>
- [20] Pan X, Liu M, Zhong F, et al. MATE: Benchmarking multi-agent reinforcement learning in distributed target coverage control[C]//*Advances in Neural Information Processing Systems 36 (NeurIPS 2022)*. 2022: 27862-27875. <https://doi.org/10.5555/3600270.3602291>
- [21] Chiun J, Zhang S, Wang Y, et al. MARVEL: Multi-agent reinforcement learning for constrained field-of-view multi-robot exploration in large-scale environments[J]. *arXiv preprint arXiv:2502.20217*, 2025. <https://doi.org/10.48550/arXiv.2502.20217>
- [22] Yu C, Velu A, Vinitzky E, et al. The surprising effectiveness of PPO in cooperative multi-agent games[C]//*Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track*. 2022. <https://doi.org/10.48550/arXiv.2103.01955>